

## Ch 2: Optimization Task

### # 2.1 Bayesian Estimation Perspective

\* Opt. Prob. 형식

$$\hat{x} = \underset{x}{\operatorname{argmin}} (DC(x, y) + \lambda R(x))$$

- 여기서  $DC(x, y)$ 는 데이터 일관성항 - 측정 신호  $x$ 가 측정  $y$ 와 일치할때 작다.
- $R(x)$ 는 정규화항, priori 에 따라  $x$ 가 있을 가능성이 높을때, 작다
- 정규화 매개변수  $\lambda \geq 0$ 는 데이터 일관성과 정규화항 간의 균형을 조절한다

### \* Bayesian Estimation

- 목표: 측정  $y$ 를 기반으로 신호  $x$ 를 추정하는 것
- Bayes' Rule 적용해서, MAP (Maximum A Posteriori) Estimator를 유도할 수 있다.

$$\hat{x} = \underset{x}{\operatorname{argmax}} p(x|y) = \underset{x}{\operatorname{argmax}} \frac{p(y|x)p(x)}{p(y)} = \underset{x}{\operatorname{argmax}} p(y|x)p(x) = \underset{x}{\operatorname{argmin}} [\log p(y|x) - \log p(x)]$$

조건부, Bayes 룰       $y$ 는 상관  $x$       로그를 쓰면 계산을 쉽게 하고

→ e.g) log-likelihood term in inverse Problem

(log-likelihood 가장 common: Least Square Loss, data가  $y = Ax$  라고 가정했을때  $x \sim N(0, \sigma^2 I)$ )

$e$ 는 Gaussian noise,  $p(y|x)$  is Gaussian with mean  $Ax$ , co-variance matrix  $\sigma^2 I$

그럼:  $p(y|x) \sim \exp\left(-\frac{1}{2\sigma^2} \|Ax - y\|_2^2\right)$  이고  $\rightarrow$  log-likelihood:  $-\log(p(y|x)) = \frac{1}{2\sigma^2} \|Ax - y\|_2^2 + C$ .

- 측정값  $y = Ax + e$  일때 데이터 일관성항  $\rightarrow DC(x, y) = \frac{1}{2} \|Ax - y\|_2^2$  이다.
- 여기서 신호가 희소하다고 가정하면 정규화 항은,  $l_1$ -Norm 사용 가능  $\Rightarrow R(x) = \|x\|_1$

따라서) 밝은 환경의 디카에서 노이즈를 Gaussian 근사하는 것 매우 good.

• digital camera measurement noise 1) Photon noise (광자 노이즈)

빛 자체의 노이즈, 물리적 측정관계에서 기인함. Poisson distribution

2) Sensor-related noise (센서 노이즈)

회로, OpAmp 등 전자장비에서 발생, 보통 additive Gaussian noise

밝은 환경에서 photon (광자) 수 많음  $\rightarrow$  Poisson  $\approx$  Gaussian 근사가 됨  $\rightarrow$  noise 전체가 Gaussian이라고 가정해도 OK

BUT)

CT, PET 등 저조도 환경 (dark condition) 에서 photon 수  $\downarrow \rightarrow$  Poisson 분포 그대로 고려 or 다른 분포가 정량화 가능

예?

Laplace, impulse, multiplicative etc

Gaussian noise  $\rightarrow$  log-likelihood는 least-squares loss와 일치:

$$-\log(p(y|x)) \sim \|Ax - y\|_2^2$$

모델  $y = Ax + e$  를 사용해서 noise 를 고려하자.

Bayesian 관점, likelihood + prior 결합해서

posterior distribution 을 얻고, 그중 가장 확률 높은

$x$  를 선택하는 MAP 로 문제를 풀기보다.

(그런데 알고보니 MAP Estimation이 regularized-

optimization 과 수학적으로 동일하네?)

# \* Bayesian Estimation

$$\hat{x} = \underset{x}{\operatorname{argmax}} p(x|y) = \underset{x}{\operatorname{argmax}} \frac{p(y|x)p(x)}{p(y)} = \underset{x}{\operatorname{argmax}} p(y|x)p(x) = \underset{x}{\operatorname{argmin}} [\log p(y|x) - \log p(x)]$$

조건부,  
Bayes 룰

y는  
상관 x

로그를 선택  
계산을 쉽게 하라

$$\hat{x} = \underset{x}{\operatorname{argmax}} ( \quad ) \rightarrow \hat{x} = \underset{x}{\operatorname{argmin}} -(\log p(y|x) - \log p(x))$$

형태로 바꾸면  $-\log p(x)$  가

• 우리가 x에 대해 알고 있는 사전 정보를 나타냄.

• 최적화문제에 regularization term

$$-\log p(x) \doteq \lambda \sigma^2 R(x) \text{로 쓰면}$$

$$\hat{x} = \underset{x}{\operatorname{argmin}} \underbrace{\frac{1}{2} \|Ax - y\|_2^2}_{\text{likelihood}} + \underbrace{\lambda R(x)}_{\text{regularizer / trade-off}}$$

해소된 문제)

1. Bayesian prior는 수학적으로 regularizer로 해석가능
2. MAP estimator는 결국 regularized loss minimization
3. inverse problem이 ill-posed 문제라 안정적 해를 찾는 데 필수조건이다.

그럼 regularizer는 뭐를 쓰는데?

## # 2.2 Common Regularizers

①  $l_2$  Regularizations :  $R(x) = \|x\|_2^2$  a.k.a. Tikhonov Regularization, 과도하게 부드러운 이미지도 이어질수있다.

classical

MAP with Gaussian Prior

②  $l_1$  Regularizations :  $R(x) = \|x\|_1 \rightarrow$  sparsity-promoting, linked to Laplace prior

③ Total Variation (TV) Regularization :

$$R(x) = \sum_i |x_i - x_{i+1}|$$

• 이미지의 날카로운 가장자리를 유지하는데 효과적 (can retain sharp edges)

• 가속 자기공명영상? (accelerated magnetic resonance image)에 good!

④ Sparse Regularization :

$$R(x) = \|Dx\|_1$$

• 특정 기저에서 신호가 희소할때 사용

• 파동기저 이용한 희소정규화(sparsifying basis)도 natural images에 good!

⋮

### # 2.3 Enhancing Deconvolution Stability through Tikhonov Regularization

Idea: Regularization은 단순히 "좋은 해"를 얻기 위한 수단 뿐만 아니라 Stability를 확보할때 필수적.

inverse Problem이 noise에 매우 민감함 (ill-posed), 그리고 Regularized problem은 다음 성질을 가짐

- ① Solution exists ② Solution unique ③ Solution stable

trade-off · Regularization 너무 세면 → bias 발생 (small noise → small change in solution)  
 너무 약하면 → variance 커짐

#### \* e.g) 1-dim Deconvolution Problem

- 목표: noise가 포함된  $y = Ax + e$ 로부터 신호  $x$  복원하기.
- consider the least-square estimate  $\hat{x}_{ls}(y) = \underset{x}{\operatorname{argmin}} \|Ax - y\|_2^2$
- 일반적으로  $\hat{x}_{ls}(y) = A^{-1}y = x + V\Sigma^{-1}U^Te$ 로 볼 수 있다,  $A = U\Sigma V^T$ 는 SVD (Singular Value Decomposition)
- noise  $e=0$ : LSE는 신호  $x$ 를 완벽 복구 가능
- noise  $e \neq 0$ :  $A$ 가 poorly conditioned하므로 가장 작은 특이값에 대한 가장 큰 값의 비율이 매우 크다  
 (the fraction of largest over smallest singular value is very large)

error)

$$E[\|\hat{x}_{ls}(y) - x\|_2^2] = E[\|V\Sigma^{-1}U^Te\|_2^2] = E[\|\Sigma^{-1}U^Te\|_2^2]$$

$V$  is unitary


•  $V$  orthogonal matrix  $\Rightarrow$  Norm 같음  
 $\|Vz\|_2 = \|z\|_2$

#### \* Regularized Least-Square Estimate

• 정규화된 estimator :

$$\hat{x}_\lambda(y) = \underset{x}{\operatorname{argmin}} (\|Ax - y\|_2^2 + \lambda \|x\|_2^2) \xrightarrow{\text{closed-form}} \hat{x}_\lambda(y) = V \operatorname{diag}(\frac{\sigma_1^2}{\sigma_1^2 + \lambda}, \dots, \frac{\sigma_d^2}{\sigma_d^2 + \lambda}) V^T x + V \operatorname{diag}(\frac{\sigma_1}{\sigma_1^2 + \lambda}, \dots, \frac{\sigma_d}{\sigma_d^2 + \lambda}) U^T e$$

• Gaussian kernel의 Deconvolution Problem에 대한 bias-variance trade off 그래프



→ (Right graph) The expected mean-squared reconstruction

$$E[\|\hat{x}_\lambda(y) - x\|_2^2] = \underbrace{\sum_{i=1}^n \left(1 - \frac{\sigma_i^2}{\sigma_i^2 + \lambda}\right)^2 (V_i^T x)^2}_{\text{bias}} + \underbrace{\sigma^2 \sum_{i=1}^n \left(\frac{\sigma_i^2}{\sigma_i^2 + \lambda}\right)}_{\text{variance}}$$

★ bias-variance trade off를 통해 최적의 파라미터  $\lambda$ 를 선택해 더 나은 신호 estimate을 할 수 있음.

#### L2 vs L1 적분

$R(x) = \|x\|_2^2 = \sum x_i^2$   
 $\text{Loss}(x) = \min \frac{1}{2} \|Ax - y\|_2^2 + \lambda \|x\|_2^2$   
 모든 변수 제공함  
 크기가 큰 값 억제  
 모든 값을 작게 만들자 → 해가 dense  
 (부드럽게 다 줄여)

$R(x) = \|x\|_1 = \sum |x_i|$   
 $\text{Loss}(x) = \min \frac{1}{2} \|Ax - y\|_2^2 + \lambda \|x\|_1$   
 희소성(sparsity) 유도  
 어떤 값을 아예 0으로 만들자 → 해가 sparse