

Linear & Ridge Regression → ML에서 강하게 다 Regression? Σ Linear Regression, closed-form 해 \checkmark (계산 빠름)

* Regression - the Problem of \angle quantity of interest y : Response / dependent variable
several observed variables x_1, x_2, \dots, x_n : covariates, features, independent variables
ex) v : house

ex) y : house

x_1 : price

x_2 : room number

x_3 : age of house

...

$x_1, x_2, x_3 \dots$ 컨디션을 ** 잘 예측 ** 해서 조건에 부합하는 best 집을 찾아보자!
(손해 받지 않는 선택을 하겠다!!!)
회사의

1. 문제 세팅 (How the response determined?)

- data : $\mathcal{D} = \{(y_1, x_1), (y_2, x_2), \dots, (y_n, x_n)\}$, $x_i \in \mathbb{R}^n$, $y_i \in \mathbb{R}$

- function: $\begin{bmatrix} y_i = \langle x_i, \theta^* \rangle + z_i \\ y_i = h^*(x_i) + z_i \end{bmatrix}$ $z_i = \text{noise}$, $h^* = \text{true underlying assumption}$

- goal: 어떻게 하면 잘 예측 할수 있을까? $\Rightarrow \theta^*, h^*$ 찾기

* 문제 θ^*, h^* 에 어떤 힌트도 없음 \rightarrow Suppose : the function h is lies in hypothesis class \mathcal{H} ,
the set of function \mathcal{H} is parameterized by a vector θ .

e.g.) Linear function: $\mathcal{H}_{\text{linear}} = \{ \text{ho}(x) = \langle x, \theta \rangle : \theta \in \mathbb{R}^d \}$

→ 의미) 함수 h 는 θ 에 의해 결정된다.

0는 수많은 data로 학습, 각 게임에 대해 잘 아 잘못 예측했네 비교해서 공통점을 찾아보자!

- Loss function (손실함수)

- * how well the prediction $h_\theta(x)$ describes output y .

$$\hat{\theta} = \arg \min_{\theta} \sum_{i=1}^n \text{loss}(h_{\theta}(x_i), y_i) \rightarrow \text{loss} \text{ 이 가장 작게}$$

1.1 Linear Regression

- Linear Model Assumption

$$y_i = \langle x_i, \theta^* \rangle + z_i, \quad x_i: \text{feature vector}, \theta^*: (\text{우리가 찾는}) \text{ parameter}, z_i: \text{노이즈}$$

$$\theta_0 + \Rightarrow y_i = \theta_0 + \langle X_i, \theta^* \rangle + z_i = \begin{bmatrix} \theta_0 \\ \theta \end{bmatrix} + \underbrace{\begin{bmatrix} \\ \end{bmatrix}}_{x} \underbrace{\begin{bmatrix} \\ \end{bmatrix}}_{\theta} + \underbrace{\begin{bmatrix} \\ \end{bmatrix}}_{z_i} = \langle \tilde{\theta}, \tilde{x}_i \rangle + z_i$$

- **loss function** 데이터를 잘 설명하는 θ 를 찾자 \rightarrow 그걸 모델이 얼마나 잘 예측하는데? \rightarrow 평가 지표 (metrics)를 만들어보자!

sum of squared errors $\hat{R}(\theta) = \frac{1}{n} \sum_{i=1}^n (\langle x_i, \theta \rangle - y_i)^2$ 해석) 예측값과 실제값 사이의 오차를 제곱해서 더한 값
1) 오차의 크면 큰 편이다. 2) 과피합하는 (차별화)

$$= \frac{1}{n} \|y - X\theta\|^2$$


1) 오차 크면 큰 페널티 2) 미분 가능 (최적화)

- 추가)

- 기하학적 해석 : $X\hat{\theta}_{LS}$ 는 y 를 X 의 열공간에 직교 투영

- 추정값의 성질 : 1) Unbiased $E[\hat{\theta}_{LS}] = \theta^*$

2) Variance $\propto \sigma_{\min}(X)^{-2}$ 즉, X 의 singular value 에 반비. \rightarrow multicollinearity possible



1.2 Least Squares

$$\hat{R}(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \langle x_i, \theta \rangle)^2 = \frac{1}{n} \|y - X\theta\|_2^2$$

• Suppose 1) $X \in \mathbb{R}^{n \times d}$ matrix

2) full column rank \rightarrow 열들이 선형독립! \rightarrow

Proposition 1: If X has full rank, $\hat{\theta}_{ls} = (X^T X)^{-1} X^T y$

1.2.1 Convex Optimization based on proof of Prop.1

\rightarrow Prop.1 을 Convex Optimization 관점에서 증명해보자.

왜? 다른 모델 (logistic Reg, ...) 에도 확장가능.

Proposition 2. Optimality Condition (최적성 조건)

function f is convex & differentiable, } x^* is global minimizer
Consider a point x^* obeying $\nabla f(x^*) = 0$

수식) $f(y) \geq f(x^*) + \underbrace{\langle y - x^*, \nabla f(x^*) \rangle}_{=0}$

$\rightarrow f(y) \geq f(x^*) \quad \square$

• Least Square 에 적용해보자.

• function $f(\theta) = \frac{1}{n} \|X\theta - y\|_2^2$

• $f(\theta)$ is convex, diff-ble

• Gradient) $\nabla f(\theta) = \langle X\theta - y, X\theta - y \rangle$
 $= \langle \theta, X^T X \theta \rangle - 2 \langle \theta, X^T y \rangle + \langle y, y \rangle$

• Linear Algebraic Proof (가법학적) $\hat{\theta}_{ls}$ 의 의미

$\rightarrow y$ 를 $X\theta$ 로 가장 가깝게 근사한 Projection (직교 투영)

• $X\theta$ 는 X 의 column vector 위에 존재

• 우리는 y 에 가장 가까운 벡터 $X\hat{\theta}$ 를 찾고싶어

수식)

• $X \in \mathbb{R}^{n \times d}$ has full column rank,

• $U \in \mathbb{R}^{n \times d}$, 직교 열 벡터 column orthogonal

• $\Sigma \in \mathbb{R}^{d \times d}$, 대각행렬 singular value $\sigma_1, \sigma_2, \dots, \sigma_d > 0$

• $V \in \mathbb{R}^{d \times d}$, 정규 직교행렬, orthogonal

$$X = U \Sigma V^T$$

★

1. Linear Regression 해가 존재하나?

2. 있다면 어떻게 구하는데?

3. 이게 왜 좋은/나쁜 해일까?

$X^T X$ invertible possible (if not) \neq singular matrix

= 역행렬 없음

\rightarrow 계산 불가 \rightarrow 해 없음

• Definition 1: What is 볼록 convex?

어떤 미분가능한 함수 f 가 다음 조건을 만족하면 convex하다고 함.

$$f(y) \geq f(x) + \langle y - x, \nabla f(x) \rangle$$

$$\langle y - x, \nabla f(x) \rangle + f(x)$$

\rightarrow 그래프가 접선보다 위에있는 함수

$$\nabla f(\hat{\theta}) = 2X^T X \theta - 2X^T y$$

$$\nabla \hat{R}(\hat{\theta}_{ls}) = 0$$


$$\Rightarrow 0 = X^T X \hat{\theta}_{ls} - X^T y$$

$$\Rightarrow X^T X \hat{\theta}_{ls} = X^T y$$

$$\Rightarrow \hat{\theta}_{ls} = (X^T X)^{-1} X^T y \quad \square$$

*그림 결론?

"gradient = 0"인 경우 \Rightarrow 해! 라인 재형가능.



$$\hat{\theta}_{ls} = (X^T X)^{-1} X^T y$$

$$U^T U = I$$

$$\bullet X^T X = (U \Sigma V^T)^T (U \Sigma V^T) = (V \Sigma^T U^T) (U \Sigma V^T)$$

$$= V \Sigma^T \Sigma V^T = V \Sigma^2 V^T$$

$$\Rightarrow (X^T X)^{-1} = (V \Sigma^2 V^T)^{-1} = V \Sigma^{-2} V^T$$

$$V^{-1} = V^T$$

$$\bullet X^T y = (U \Sigma V^T)^T y = V \Sigma^T U^T y$$

$$\Rightarrow \hat{\theta}_{ls} = V \Sigma^{-2} V^T \cdot V \Sigma^T U^T y = V \Sigma^{-1} U^T y$$

$$\bullet X \hat{\theta}_{ls} = U \Sigma V^T \cdot V \Sigma^{-1} U^T y = U U^T y$$

$X \hat{\theta}_{ls} = U U^T y$ 의 의미) $U U^T$ 는 X 의 column space 에 대한 projection matrix

Ridge Regression

(idea) LR에서 $\hat{\theta}_{LS}$ 가 과하게 변하거나, 과하게 작아지는 문제를 해결하기 위해 해를 좀 더 제약해 안정적인 추정을 해보자

2.1 Ridge Regression Estimate

- $\hat{\theta}_{LS} = \arg\min \|\mathbf{y} - \mathbf{X}\theta\|_2^2$ (기준)
- 아주 큰 $\|\theta\|$ 는 예측을 불안하게 해. $\rightarrow \|\theta\|$ 를 컨트롤 해보자
 $\rightarrow \|\theta\|$ 에 자체 패널티
- 여전히 convex, diff-able $\Rightarrow \exists$ closed-form 해.

$$\hat{\theta}_{ridge} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

SVD 기반 해석) shrinkage 관점.

• \mathbf{X} 를 SVD, $\mathbf{X} = \mathbf{U} \Sigma \mathbf{V}^T$

$$\mathbf{X} \hat{\theta}_{ridge} = \sum_{i=1}^d \frac{\sigma_i^2}{\sigma_i^2 + \lambda} \langle \mathbf{y}, \mathbf{u}_i \rangle \mathbf{u}_i$$

shrink factor $\in (0, 1)$

\rightarrow 해석) 각 방향 \mathbf{u}_i 에 대해 shrink factor 를 곱한다.

즉, data 가 약한 방향 (작은 σ_i) 에서는 bias 를 많이 줄인다

\rightarrow 노이즈에 덜 민감 (더 정확하게)

$$\hat{\theta}_{ridge} = \arg\min_{\theta} \underbrace{\|\mathbf{y} - \mathbf{X}\theta\|_2^2}_{\text{fitting error}} + \underbrace{\lambda \|\theta\|_2^2}_{\text{regularization penalty}}$$

$\lambda > 0$: reg. parameter
 \uparrow (크면 더 강한 제약)

$$\begin{aligned} \mathbf{X} \hat{\theta}_{ridge} &= \mathbf{X} (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y} \\ &= \mathbf{U} \Sigma \mathbf{V}^T (\mathbf{V} \Sigma^T \mathbf{U}^T \mathbf{U} \Sigma \mathbf{V}^T + \lambda \mathbf{V} \mathbf{V}^T)^{-1} \mathbf{V} \Sigma \mathbf{U}^T \mathbf{y} \\ &= \mathbf{U} \Sigma \mathbf{V}^T (\mathbf{V} (\Sigma^2 + \lambda \mathbf{I}) \mathbf{V}^T)^{-1} \mathbf{V} \Sigma \mathbf{U}^T \mathbf{y} \\ &= \mathbf{U} \Sigma \mathbf{V}^T \mathbf{V} (\Sigma^2 + \lambda \mathbf{I})^{-1} \mathbf{V}^T \mathbf{V} \Sigma \mathbf{U}^T \mathbf{y} \\ &= \mathbf{U} \Sigma (\Sigma^2 + \lambda \mathbf{I})^{-1} \Sigma \mathbf{U}^T \mathbf{y} \end{aligned}$$

diagonal matrix with $\sigma_i^2 + \lambda$

$$\Rightarrow (\Sigma^2 + \lambda \mathbf{I})^{-1} = \text{diagonal matrix with } \frac{1}{\sigma_i^2 + \lambda}$$

• Σ = diagonal matrix with σ_i

$$\Rightarrow \Sigma (\Sigma^2 + \lambda \mathbf{I})^{-1} \Sigma = \text{diag} \left(\frac{\sigma_1^2}{\sigma_1^2 + \lambda}, \dots, \frac{\sigma_d^2}{\sigma_d^2 + \lambda} \right)$$

$$\Rightarrow \mathbf{U} \mathbf{U}^T \mathbf{y} = \sum \mathbf{u}_i \langle \mathbf{u}_i, \mathbf{y} \rangle = \sum \langle \mathbf{y}, \mathbf{u}_i \rangle \mathbf{u}_i$$

• $\lambda = 0$: 일반 LS (Bias 0, Var \uparrow)

최적 λ 선택 방법 • $\lambda \rightarrow \infty$: $\hat{\theta}_{ridge} \rightarrow 0$ (극단적 단원화)

• 보통 cross-validation 사용

2.2 Bias - Variance - Trade off

• Ridge Reg. 추정값에 bias 를 일부 도입 \rightarrow Variance 줄임.

factor	Least Squares	Ridge Regression
Bias	low (0)	high
Variance	大	小
예측 오차	overfitting possible	control with λ

Optimization: Maximum Likelihood Estimate

- A method of estimating the parameters of a statistical model given observations by finding the parameter values that maximize the likelihood of making the observations given the parameters

$$\theta_{ML} = \arg \max_{\theta} p_{\text{model}}(y|x, \theta)$$

- Approach

$$\theta_{ML} = \arg \max_{\theta} \prod_{i=1}^n p_{\text{model}}(y_i|x_i, \theta)$$

training samples are independent, generated by same probability distribution (i.i.d)

- We can replace the product by applying the logarithmic property $\log_c(ab) = \log_c(a) + \log_c(b)$:

$$\theta_{ML} = \arg \max_{\theta} \sum_{i=1}^n \log p_{\text{model}}(y_i|x_i, \theta)$$

what shape does our probability distribution have?
 $y_i = \mathcal{N}(x_i, \theta, \sigma^2) = x_i \theta + \mathcal{N}(0, \sigma^2)$
 Gaussian mean
 * 등차 *

- Assuming Gaussian distribution, we get the same result for the optimization as for Linear least squares

$$\theta = (X^T X)^{-1} X^T y$$

$$* p(y_i|x_i, \theta) = (2\pi\sigma^2)^{-\frac{1}{2}} e^{-\frac{1}{2\sigma^2}(y_i - x_i\theta)^2}$$

Assuming $y_i = \mathcal{N}(x_i, \theta, \sigma^2) = x_i\theta + \mathcal{N}(0, \sigma^2)$

cf) Gaussian:

$$p(y_i) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(y_i - \mu)^2} \quad y_i \sim \mathcal{N}(\mu, \sigma^2)$$

mean

original optimization problem

$$\theta_{ML} = \arg \max_{\theta} \sum_{i=1}^n \log p_{\text{model}}(y_i|x_i, \theta)$$

$$\log \left[(2\pi\sigma^2)^{-\frac{1}{2}} e^{-\frac{1}{2\sigma^2}(y_i - x_i\theta)^2} \right]$$

$$\sum_{i=1}^n \log \left[(2\pi\sigma^2)^{-\frac{1}{2}} e^{-\frac{1}{2\sigma^2}(y_i - x_i\theta)^2} \right]$$

$$= \sum_{i=1}^n -\frac{1}{2} \log(2\pi\sigma^2) + \sum_{i=1}^n \left(-\frac{1}{2\sigma^2} \right) (y_i - x_i\theta)^2$$

$$= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} (y - X\theta)^T (y - X\theta)$$

$$\downarrow \frac{\partial J(\theta)}{\partial \theta} \stackrel{!}{=} 0 \Rightarrow \theta = (X^T X)^{-1} X^T y$$

$p_{\text{data}}(y|x)$: true underlying distribution (observation)

$p_{\text{model}}(y|x, \theta)$: Parametric family of distribution

어떤 데이터를 막았는데 너무 많아서 근제 어떤 분포인지 몰라.

각 파라미터마다 스프 벡터가 다르고, 어떤 스프 벡터가 가장 잘 맞는 건지 벡터를 찾아보자!

→ 여러번 근제를 시작하면서 data를 만들었어.

변수	스프 벡터	근제 값
...

목표: 진짜 스프 벡터를 찾자. = 값(y)이 스프(x)에 따라 어떻게 정해졌는지 추정해봐.

① Least squares ② Maximum Likelihood ...

① Least Squares (가장확관점)

• 정답 θ 는 존재한다

• θ 를 넣어서 예측한 값 $\hat{y}_i = x_i\theta$ 이 실제 값 y_i 와

얼마나 비슷한지 본다.

→ 근제를 지을수록 진짜 더한게 가장 작은게 best.

* Interpretation *

값(y)이 얼마나 예측과 가까운지를 기준으로 θ 를 찾자

② Maximum Likelihood

• data는 확률 model에서 뽑았을 확률. $y_i \sim \mathcal{N}(\theta x_i, \sigma^2)$

• "어떤 θ 를 사용했을때 실제 값(y)이 나를 확률"이 가장 높은 걸 찾자.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} \prod_{i=1}^n \mathcal{N}(y_i | \theta x_i, \sigma^2)$$

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \Rightarrow B \text{가 일어났을때 } A \text{가 일어날 확률}$$

* Interpretation *

지금 막 본 결과들이 실제로 나를 확률이 가장 높은 θ 를 찾자.

= 가장 그럴듯한 θ 를 찾자.

• why?

$$y = ax + b, \dots$$

LS가 직관적이어서 "왜 그 공식을 사용하는지"의 근거 부족

MLE는 "data가 대 어떻게 나왔는가"를 확률적으로 설명가능

3.3 Bias-Trade-off Ridge Regression 이 때 일반화 성능이 좋은지 수학적으로 알아보자.
 예측 실수를 Bias² + Variance + Noise 로 분해해서 어떻게 Variance를 줄여주는지 분석해보자

• 문제 설정 - Prediction Risk of $\hat{\theta}$

→ 새로운 샘플 $x \in \mathbb{R}^d$ 에 대해 예측할때 (예측 리스크)
 • Model: $y = h(x) + z, z \sim \mathcal{N}(0, \sigma^2)$
 • Dataset: $\mathcal{D} = \{(y_1, x_1), \dots, (y_n, x_n)\}$
 • 예측값: $\hat{y} = \hat{h}(x) = \langle \hat{x}, \hat{\theta}_{ridge} \rangle$
 • 실제값: $y = \langle x, \theta^* \rangle + z, z \sim \mathcal{N}(0, \sigma^2)$

Prediction Risk $R(\hat{h}) = E_{x,y}[(\hat{h}(x) - y)^2]$
 + Dataset random (확률)
 $\Rightarrow E_{\mathcal{D}}[R(\hat{h}_{\mathcal{D}})] = E_{x,y,\mathcal{D}}[(\hat{h}_{\mathcal{D}}(x) - y)^2]$

• Goal: $E_{x,y,\mathcal{D}}$ 를 Bias, Variance, Noise 로 분해.

• 수식)

$$E_{\mathcal{D}}[R(\hat{h}_{\mathcal{D}})] = E_{x,y,\mathcal{D}}[(\hat{h}_{\mathcal{D}}(x) - y)^2] = E_{\mathcal{D}}[(\hat{h}_{\mathcal{D}}(x) - h(x) - z)^2]$$

$$= E_{\mathcal{D}}[(\hat{h}_{\mathcal{D}}(x) - h(x))^2] + 2E[(\hat{h}_{\mathcal{D}}(x) - h(x))z] + E[z^2]$$

$$= E_{\mathcal{D}}[(\hat{h}_{\mathcal{D}}(x) - h(x))^2] + E[z^2] \quad \text{z has zero mean.}$$

$$E_{\mathcal{D}}[(\hat{h}_{\mathcal{D}}(x) - h(x))^2] = E_{\mathcal{D}}[(\hat{h}_{\mathcal{D}}(x) - E[\hat{h}_{\mathcal{D}}(x)] + E[\hat{h}_{\mathcal{D}}(x)] - h(x))^2]$$

$$= E_{\mathcal{D}}[(\hat{h}_{\mathcal{D}}(x) - E[\hat{h}_{\mathcal{D}}(x)])^2] - 2(E_{\mathcal{D}}[\hat{h}_{\mathcal{D}}(x)] - E[h(x)])(E[\hat{h}_{\mathcal{D}}(x)] - h(x)) + E[(E[\hat{h}_{\mathcal{D}}(x)] - h(x))^2]$$

$= 0, \because \text{기대값} \approx \text{평균}$

$$= E_{\mathcal{D}}[(\hat{h}_{\mathcal{D}}(x) - E[\hat{h}_{\mathcal{D}}(x)])^2] + E[(E[\hat{h}_{\mathcal{D}}(x)] - h(x))^2]$$

Thus we have,

$$E_{\mathcal{D}}[R(\hat{h})] = E_{\mathcal{D}}[(\hat{h}_{\mathcal{D}}(x) - h(x))^2] + E[z^2]$$

$$= \underbrace{E[(E[\hat{h}_{\mathcal{D}}(x)] - h(x))^2]}_{\text{Bias}^2} + \underbrace{E_{\mathcal{D}}[(\hat{h}_{\mathcal{D}}(x) - E[\hat{h}_{\mathcal{D}}(x)])^2]}_{\text{Variance}} + \underbrace{E[z^2]}_{\text{Noise}}$$

= 평균모델과 진짜 함수 $h(x)$ 간의 거리 학습 Dataset 변화에 따른 예측의 흔들림 예측 불확실성

* 직관적 이해...

- Bias가 크다 → 모델이 단순해서 진짜 패턴 못 따라감 (underfitting)
- Variance가 크다 → 데이터셋이 조금 바뀌면 예측이 크게 바뀜 (overfitting)
- Noise는 피할 수 없음

* 왜 중요한가? 모델 선택 & Hyperparameter 튜닝의 근거.
 ~~~~~  
 next chapter