

11. Support vector machines

- Remind) Logistic Regression : classify 2 (or F) class based on decision boundary
if inner product $\langle \theta, x \rangle$ is larger than threshold.

* Support Vector Machines (SVM)

Goal: 고차원 공간에서 선형 결정 경계를 통해 data를 분류하자

Idea: Margin을 최대화해서 일반적인 성능이 가장 좋은 classifier를 찾자.

비슷하게 SVM에서 decision boundary 확률 but data distribution 가정 안함

11.1 The perceptron algorithm (Limit & Problem)

* 시작점: Consider binary classification

- Dataset : $D = \{(x_1, y_1), \dots, (x_n, y_n)\} \in \mathbb{R}^d \times \{-1, 1\}$

- Goal: Hyperplane을 따라 2가지 클래스로 분류하는 classifier를 찾자.

- Classifier f :
$$f(x) = \begin{cases} 1, & \langle \theta, x \rangle \geq b \\ -1, & \langle \theta, x \rangle < b \end{cases}$$

* 전제 조건: data is linearly separable, data가 선형적으로 완전히 분리가능해야만 작동

* 문제점 : 1) 해가 존재하지 않을 수 있음 (linearly non-separable data)

2) 여러 해가 존재하면 어떤 θ 를 선택할지 기준 없음 (θ and b aren't necessarily unique)

→ SVM Motivation

① fully linear separable을 가정 → ② 완벽히 선형분리되지 않는 case (duality 도입)

11.2 Hard-Margin SVM

* Goal: fully linearly separable data에 대해 Margin을 최대화하는 Hyperplane 찾기

In more detail: we want to maximize margin $m \geq 0$ s.t.

1) "+1"로 분류된 모든 points는 Hyperplane의 양쪽 (positive side)에 있고, 그 Hyperplane까지의 거리는 최소 m .

1) "-1"로 분류된 모든 points는 Hyperplane의 음수쪽 (negative side)에 있고, 그 Hyperplane까지의 거리는 최소 m .

* distance of a point x to a hyperplane $H = \{x : \langle \theta, x \rangle = b\}$:

$$\text{distance}(x, H) = \frac{|\langle \theta, x \rangle - b|}{\|\theta\|_2} = \frac{|\langle \theta, x - x_0 \rangle|}{\|\theta\|_2} = \frac{|\langle \theta, x \rangle - b|}{\|\theta\|_2} \quad ***$$

By definition, the vector θ is perpendicular to Hyperplane $H \Rightarrow$ Any vector lies on Hyperplane.

만약 $x_0, x_1 \in H$ 일때 $x_1 - x_0$ vector는 H 위에 있고, orthogonal to θ :

$$\langle x_1 - x_0, \theta \rangle = \langle x_1, \theta \rangle - \langle x_0, \theta \rangle = b - b = 0$$

$\Rightarrow \theta$ 가 H 에 perpendicular, 최소 거리 ($x \sim H$)는 projection of $x - x_0$ onto θ , where $x_0 \in H$.

이걸 수식으로 표현하면 ***

이걸 우리 Goal에 대응하면 : $y_i \frac{|\langle \theta, x_i \rangle - b|}{\|\theta\|_2} \geq m$.

* Optimization Task :

1) Margin 포함

$$\max_{\theta, b} m \text{ subject to } y_i \frac{|\langle \theta, x_i \rangle - b|}{\|\theta\|_2} \geq m, \quad i \in \{1, \dots, n\}$$

2) scale normalization

$$\|\theta\|_2 = \frac{1}{m} \text{로 설정하면} \rightarrow \max_{\theta, b} \frac{1}{\|\theta\|_2} \text{ subject to } y_i \frac{|\langle \theta, x_i \rangle - b|}{\|\theta\|_2} \geq 1$$

$$\text{미분할때 수식 상에 만들고, min으로 하려고... } f(\theta) = \frac{1}{2} \|\theta\|^2 = \frac{1}{2} \theta^T \theta \rightarrow \nabla_{\theta} f(\theta) = \nabla_{\theta} \left(\frac{1}{2} \theta^T \theta \right) = \theta$$

11.3 Soft-Margin SVM → 현실 data는 대부분 완벽히 선형분리 불가능 → duality 적용 → slack variables ξ_i

Noise or Overlap이 있는 현실 data를 어떻게 다룰까? → Margin 조건을 일부 위반 허용하자

- 새로운 constraint : $y_i(\langle \theta, x_i \rangle - b) \geq 1 - \xi_i$ ($\xi_i \geq 0$)

we take the slack variable in the objective into account by penalizing large values of ξ_i

- 새로운 optimization : $\min_{\theta, b} \frac{1}{2} \|\theta\|^2 + \lambda \sum_{i=1}^n \xi_i$ subject to $y_i(\langle \theta, x_i \rangle - b) \geq 1 - \xi_i$, $\xi_i \geq 0$

$$\min_{\theta, b} \frac{1}{2} \|\theta\|^2 + \lambda \sum_{i=1}^n \max(1 - y_i(\langle \theta, x_i \rangle - b), 0) \quad \begin{cases} y_i(\langle \theta, x_i \rangle - b) \geq 1 - \xi_i \\ \xi_i \geq 0 \text{ 포함} \end{cases}$$

$$\min_{\theta, b} \frac{1}{2} \|\theta\|^2 + \lambda \sum_{i=1}^n \xi_i \text{ subject to } \xi_i = \max(1 - y_i(\langle \theta, x_i \rangle - b), 0)$$